

REAL-ESTATE-SCRAPER-CREWAI — DARBA APRAKSTS

Tika izstrādāta Python lietotne, kas ar Selenium automātiski savāc komercīpašumu sludinājumus no mājaslapas, strukturēti tos saglabā (CSV un JSON) ar Pandas un pēc tam analizē vienus un tos pašus datus trīs neatkarīgos veidos — ar LangChain, LlamaIndex un CrewAI. Projekta kodols ir uzticams scrapper (izmanto WebDriverWait, apstrādā kļūdas un nepaļaujas vienīgi uz time.sleep); trīs MI risinājumi parāda dažādu mūsdienu ietvaru pielietojumu vieniem un tiem pašiem datiem.

Mājaslapas izvēle

Projektam tika izvēlēta city24.lv mājaslapa, kas ir reāls Latvijas nekustamo īpašumu portāls ar pietiekamu ierakstu skaitu un skaidru struktūru (nosaukums, cena, kategorija, saite). Tika izvēlēta komercēplatību kategorija, jo katram objektam ir viena konkrēta cena — tīrāki dati nekā, piemēram, jaunajiem projektiem, kur cena mēdz būt diapazonā. Pirms darba tika izlasīts un ievērots lapas robots.txt: scrapping notika tikai atļautajās saraksta un lappušu lapās (neizmantojot aizliegtos filtru parametrus), nelielā apjomā (ap 150 ierakstu no trim lapām).

Datu iegūšana

Mājaslapa ir veidota ar JavaScript (React), ar aizsardzību pret botiem, tāpēc vienkāršs HTTP pieprasījums nav pietiekams. Risinājums:

1. Selenium atver lapu ar redzamu Chrome pārlūku, kas tiek cauri aizsardzībai un izpilda lapas JavaScript;
2. WebDriverWait gaida, līdz ir ielādējies īstais saturs;
3. Tiek paņemta viena statiska lapas HTML kopija, no kuras ar BeautifulSoup izvelk vajadzīgos datus;
4. Skrāpis iet cauri vairākām rezultātu lapām (ceļa segments /pg=N) ar nelielu pauzi starp tām;
5. Pandas saglabā rezultātu kā CSV un JSON.

Katram sludinājumam tiek iegūta adrese, pilsēta, kategorija, cena (gan oriģinālais teksts, gan tīra skaitliskā vērtība), platība/istabu skaits un saite uz objektu. Scrapping loģika ir apvienota vienā modulī (scraper.py), ko izmanto gan galvenā programma, gan CrewAI aģents, un tās galvenās funkcijas (datu izvilkšana un cenas attīrīšana) ir pārklātas ar automātiskiem testiem.

Novērojumi

- Dinamiska lapa ar mainīgu saturu. Lapa sākotnēji parāda tukšus ielādes vietturus (mmmmmmmm), un React darba laikā sarakstu pārzīmē. Tāpēc gaidīt tikai uz elementa parādīšanos nepietiek (arī vietturis ir elements), un dzīvas elementu atsaucēs pārzīmēšanas laikā kļūst nederīgas. Risinājums abām problēmām ir viens: nogaidīt īsto saturu un strādāt ar vienu statisku lapas kopiju, no kuras datus izvelk BeautifulSoup. Rezultāts ir stabils un atkārtojams.

- Cenas attīrīšana. Cena lapā ir teksts ar valūtas zīmi un reizēm papildu uzrakstu. Tā tika pārveidota atsevišķā skaitliskā kolonnā (saglabājot arī oriģinālo tekstu), lai datus varētu izmantot aprēķinos.
- Mainīgā MI ekosistēma. MI bibliotēkas attīstās ātri, tāpēc projekta gaitā bija jāpieņem vairāki praktiski lēmumi: pāriet no novecojušas pakotnes uz uzturētu alternatīvu, saskaņot pārāk jaunās Python versijas saderību (no 3.14 uz stabilo 3.11) un apiet bezmaksas valodas modeļu ierobežojumus, izvēloties lētu, uzticamu maksas modeli.

Trīs analīzes pieejas

- LangChain — visus skaitļus (kopskaitu, vidējo, mazāko un lielāko cenu, piecus lētākos) aprēķina Python kods, un MI tos tikai noformulē saprotamā valodā. Modelis pats neko nerēķina, tāpēc skaitļi vienmēr ir precīzi.
- LlamaIndex — dati tiek ievietoti atmiņas SQLite tabulā, un uz uzdoto jautājumu MI izveido SQL vaicājumu, to izpilda un sniedz atbildi (piemēram, kurš objekts ir lētākais, vidējā cena, biežākās pilsētas).
- CrewAI — divi aģenti sadarbojas: viens ar Selenium savāc datus, otrs sagatavo kopsavilkumu ar pieciem izdevīgākajiem piedāvājumiem.

Visas trīs pieejas deva vienādu rezultātu (piemēram, lētākais objekts — OZOLU, Aizkraukle, 1234 EUR — sakrita visās), kas apstiprina datu plūsmas pareizību.

Būtiskākais

Projekta princips bija tāds, ka MI ir kontrolēts sistēmas komponents, nevis tās lēmumu pieņēmējs. Visās trīs pieejās skaitļus un loģiku nosaka kods — MI tikai noformulē rezultātu vai izveido vaicājumu, ko izpilda kods. Tāpēc rezultāti ir precīzi un pārbaudāmi. Otra atziņa ir praktiska: uzticama risinājuma vērtība slēpjas ne tik daudz pašā funkcionalitātē, cik tās noturībā. Darbs ar reālu, dinamisku un pret botiem aizsargātu lapu prasīja stabilu tehnisko pieeju, bet mainīgā MI vide — pārdomātu, uz uzturētiem rīkiem balstītu izvēli.